

Detekce a sledování CCP

aneb „Míň je víc“

Matyáš Veselý, Ruslan Guliev

ČVUT, FJFI

UTIA, AV ČR / 15.12.2025



Formulace problému

- CCP jsou malé membránové struktury zapojené do endocytózy zprostředkované receptory.
- Tento projekt se zabývá detekcí a sledováním těchto struktur v časosběrných snímcích.
- To znamená, že musíme provést přesnou prostorovou detekci CCP v jednotlivých snímcích a časovou asociaci detekcí do koherentních trajektorií napříč videosekvencí.

Použité metody

Použili jsme spoustu různých modelů a přístupů

Mezi použité metody a modely jsou např.:

1. klasické a známe *U-net++* a *HRNetV2*,
2. předtrénovaný model založeny na architektuře transformer *SAM3*,
3. model *StarDist* pro detekci objektů ve snímcích, speciálně navržený pro segmentaci buněk a konvexních objektů,
4. pro sledování trajektorií jsme použili nástroje *Btrack* a *LapTrack*,
5. dva další **inovativní přístupy**, které posunuly výsledky vpřed!

U–net++

- Je vylepšenou verzí klasické metody na segmentaci obrazů.
- *U-Net++* na rozdíl od klasického *U-net* přidává vnořené (nested) konvoluční bloky mezi encoder a decoder, které postupně zpracovávají příznaky na různých úrovních rozlišení.
- Se zvětšujícím se množstvím trénovacích dat, výsledky se nezlepšovali souměrně.
- Proto se tento model opustil a rozvíjeli jsme model, který tento práh překonal.

HRNetV2

- *HRNet* na rozdíl od klasických sítí začíná s vysokým rozlišením a postupně paralelně přidává větve s nižším rozlišením.
- Modifikace *V2* kombinuje příznaky ze všech větví pro finální výstup, a proto je silný právě díky přesné lokalizaci objektů.
- Byl trénován na větších datasetech.
- S tímto modelem jsme dosáhli prvních dobrých výsledků, tj. dle *HOTA* metriky jsme se pohybovali kolem hodnot ≈ 0.69 pro obě trackovací metody.

Plató

Záhy poté jsme čelili problému, že jsme již nemohli výsledky metrik zlepšit. Nepomáhalo ani delší trénování, ani větší rozsah hledání vhodných parametrů. Možné příčiny:

- náš model se nehodí pro tato konkrétní data,
- problém v trénovacích datech.

Cesty se rozdělily a každý začal zkoušet svoje nápady.

Vylepšený generátor syntetických dat

První pozorování – buňky na syntetických datech skoro neodpovídají reálným umístěním buněk na validačních datech.

V reálném světě buňky často tvoří shluky a model trénovaný pouze na separátně umístěných objektech neumí v těchto shlucích detektovat jednotlivé buňky!

Původní generátor

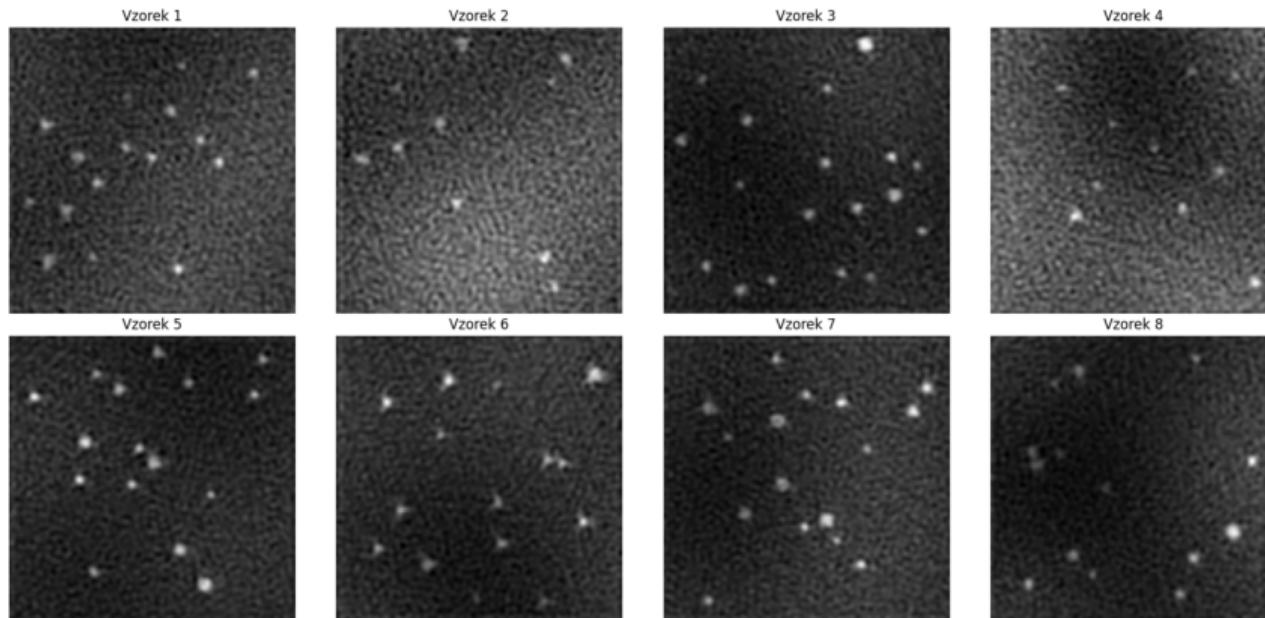


Figure: Ukázka generace syntetických dat v původním generátoru.

Reálná data

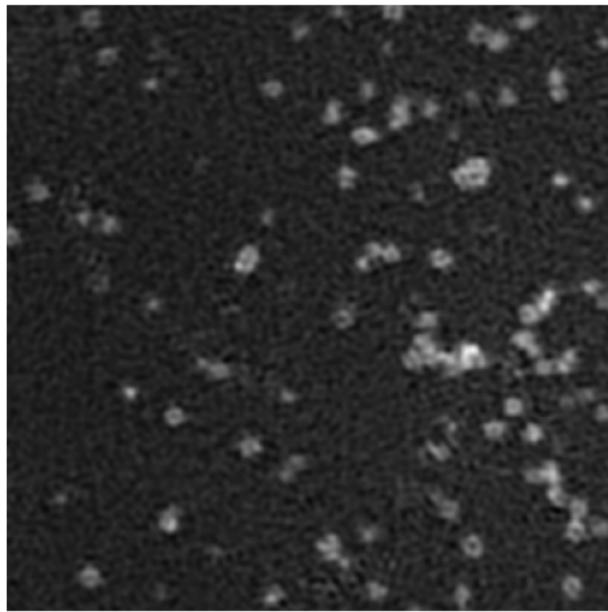
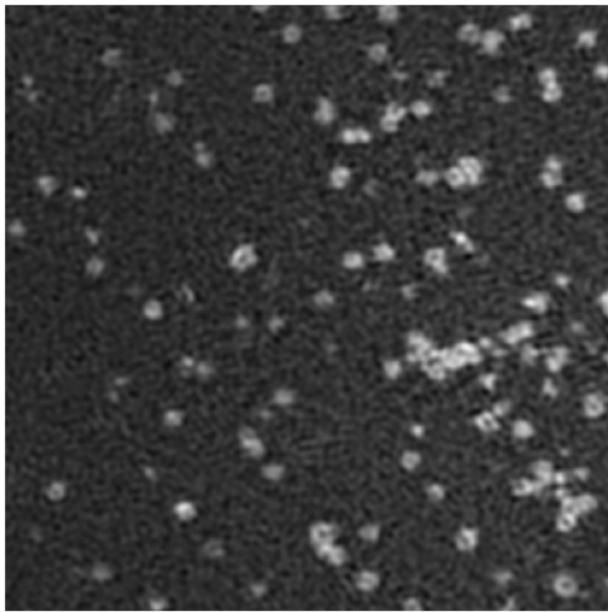


Figure: Ukázka reálných dat, které musí vyhodnotit model.

Vylepšený generátor

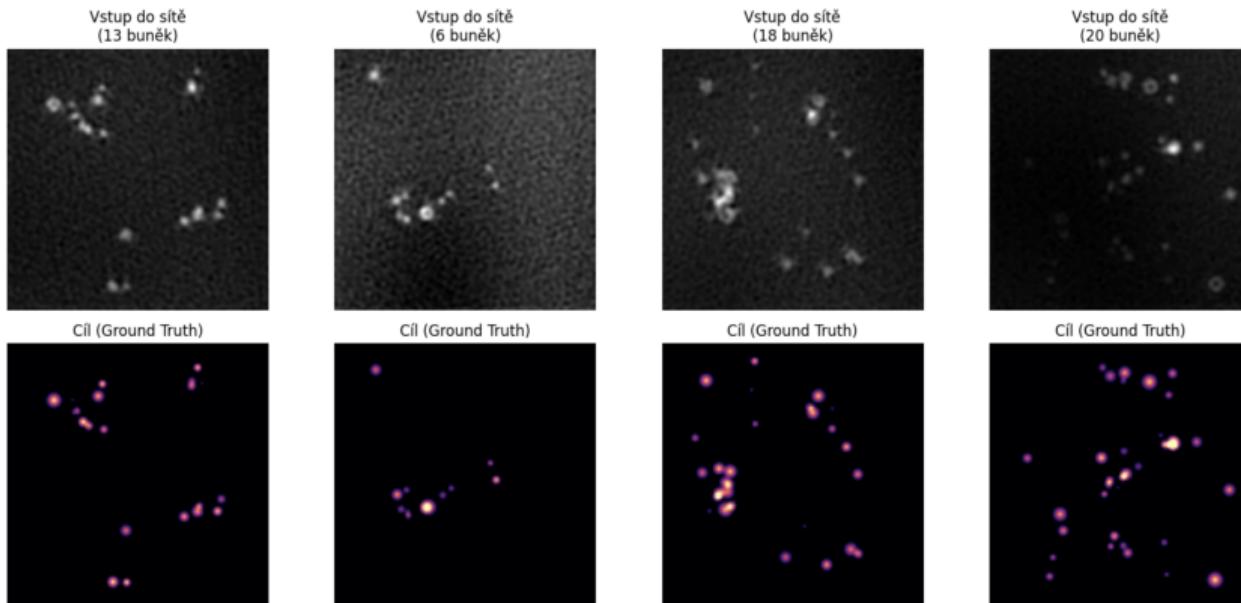


Figure: Ukázka generace syntetických dat v novém generátoru, který umí simulovat i shluky buněk.

Vylepšený generátor

Vylepšení generátoru syntetických dat a drobný finetune *HRNet* vedl k okamžitému zlepšení detekce a následně i *HOTA* dosáhla lepších hodnot, a to spolu s tím faktem, že kvůli dotrénování se zanesl šum do modelu.

HOTA	DetA	AssA
0.7272	0.7590	0.6967
0.7245	0.7628	0.6881
0.7212	0.7200	0.7225
0.7179	0.7498	0.6874
0.7099	0.7517	0.6704

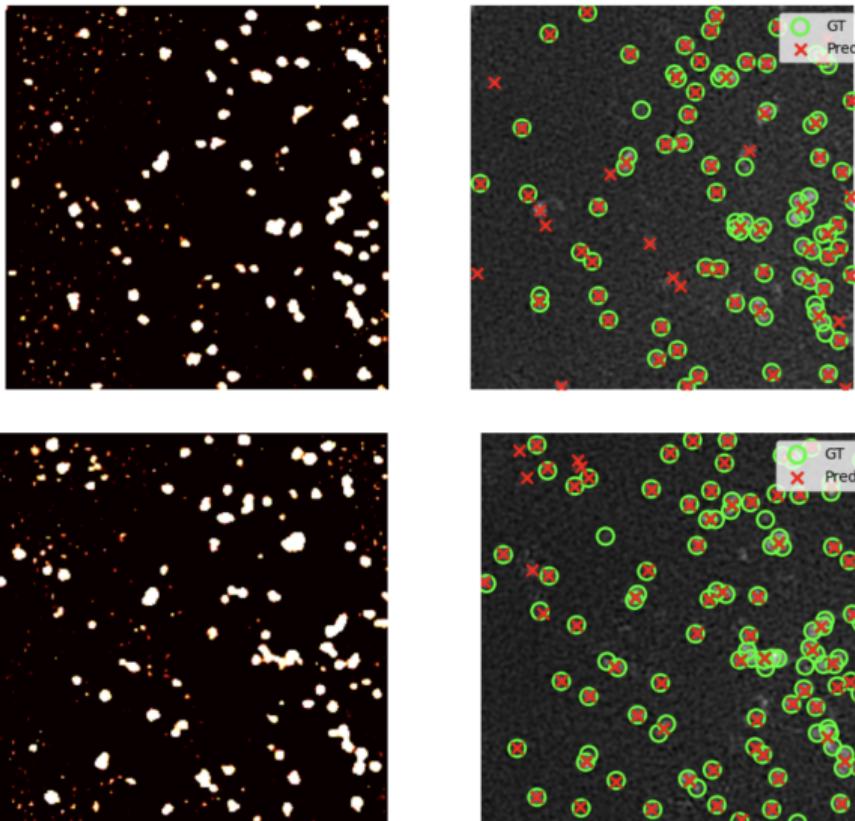


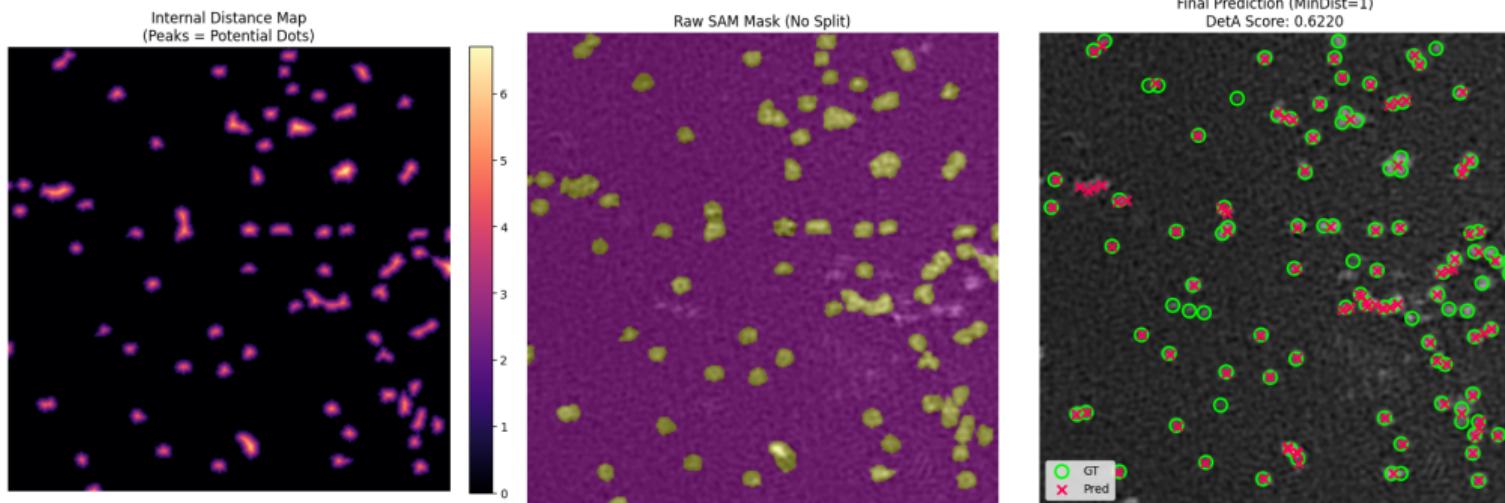
Figure: Ukázka zaneseného šumu v probability mapách.

SAM3 – Segment Anything Model 3

- SAM3 (*Meta*) je univerzální segmentační model založený na architektuře *Vision Transformer* (*ViT*).
- Model byl trénován na rozsáhlém datasetu obsahujícím miliardy masek, což mu umožňuje generalizovat na nové domény bez dodatečného trénování.
- Podporuje různé typy promptů: body, bounding boxy, textové popisy nebo automatickou detekci všech objektů.
- SAM3 jsme zvolili díky jeho schopnosti generalizace bez nutnosti velkého množství trénovacích dat, kterých je pro tento problém nedostatek.

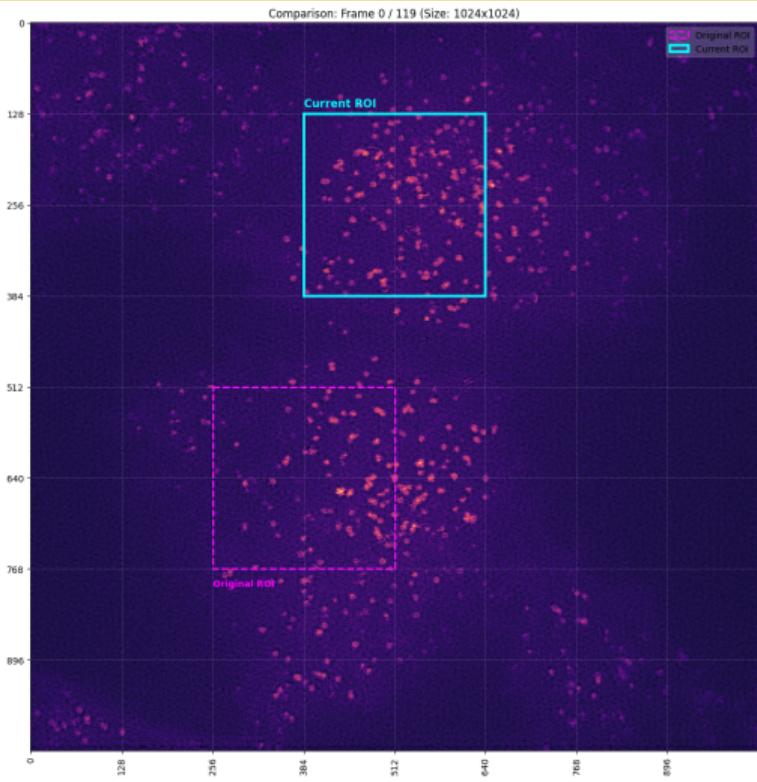
SAM3 – limitace pro buněčná data

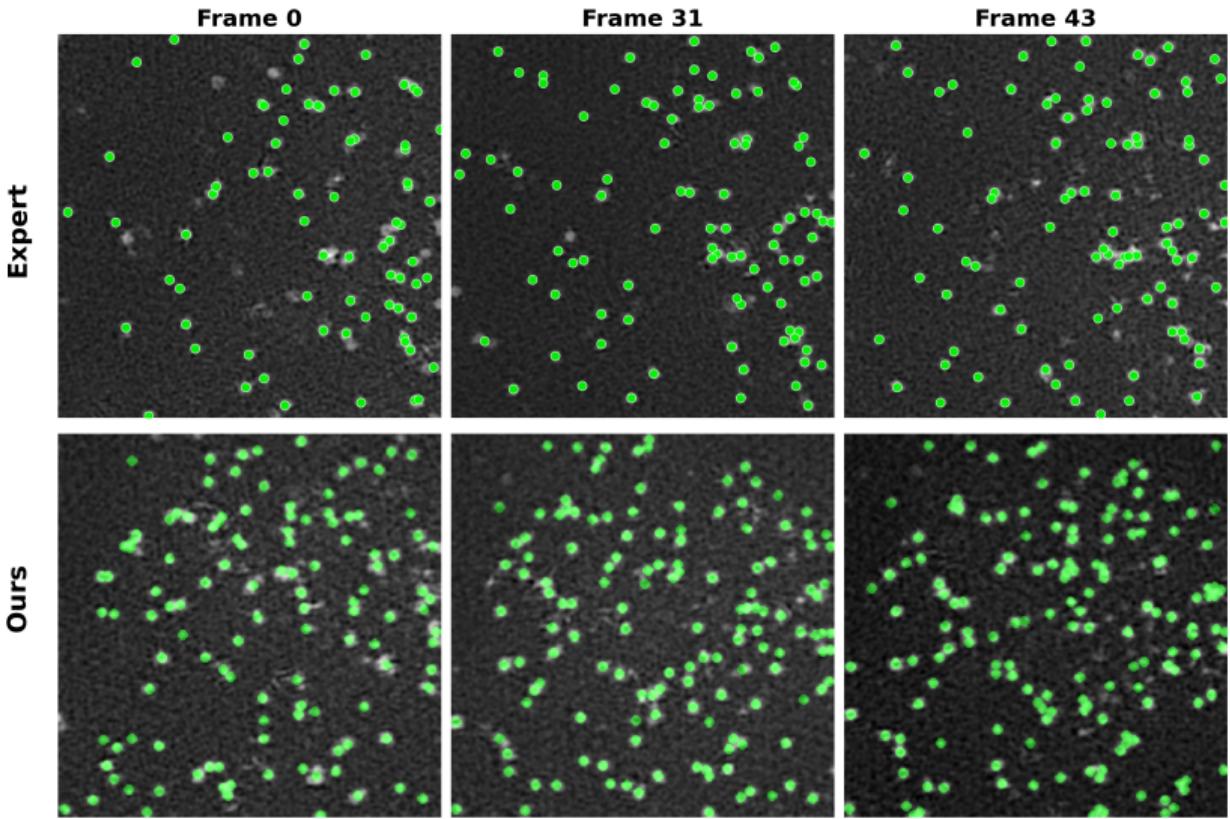
- SAM3 jako sémantický segmentátor má tendenci sloučovat husté oblasti buněk do jedné masky, což vede k velkému počtu FN detekcí.
- Nejlepších výsledků jsme dosáhli po optimalizaci promptů, prahování a aplikaci *watershed* algoritmu s hodnotou DetA ≈ 0.67 .



HITL anotační workflow

- Vyvinuli jsme *Human-in-the-Loop* workflow kombinující automatické detekce SAM3 s lidskou verifikací v *Label Studio*.
- Tímto způsobem jsme anotovali **52 nových snímků** pro trénování nebo dat validaci detektorů.
- Výhody: efektivita, kvalita (lidská kontrola FP/FN), přímá integrace do trénovací pipeline.



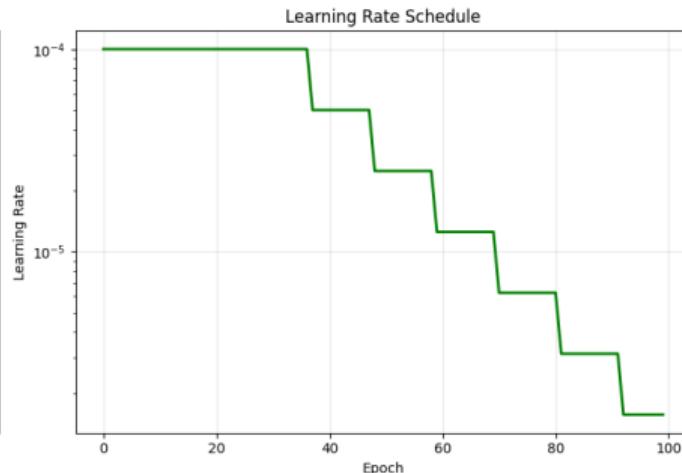
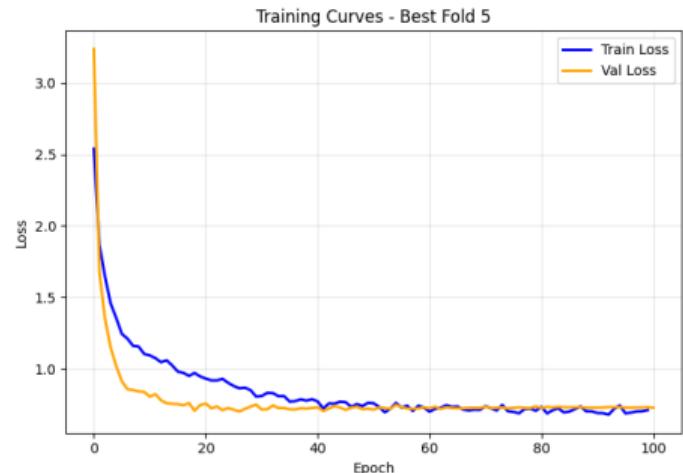


StarDist – architektura

- *StarDist* reprezentuje každou buňku jako star-konvexní polygon – pro každý pixel predikuje pravděpodobnost, že je středem buňky, a radiální vzdálenosti k hranici objektu v 64 směrech.
- Encoder: *ResNet18* (předtrénovaný na ImageNet), Decoder: U-Net s skip connections.
- Výstup: pravděpodobnostní mapa ($H \times W$) + radiální vzdálenosti ($64 \times H \times W$).
- Post-processing: Non-Maximum Suppression (NMS) odstraňuje překrývající se detekce pomocí predikovaných polygonů.

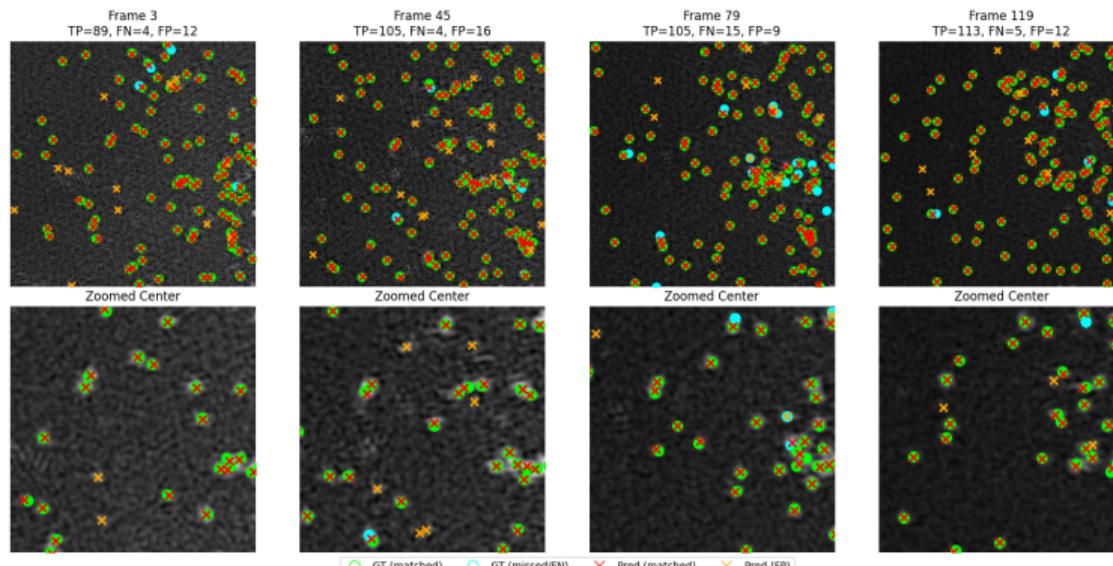
StarDist – trénování

- Trénovací data: $120 + 42$ HITL = **162 vzorků** (ROI 256×256). Bodové anotace → diskové masky ($r=3\text{px}$).
- **5-fold cross-validation**, stratifikované dle počtu buněk.
- Loss: Focal + L1 distance.
- Optimizer: AdamW, LR= 10^{-4} , Scheduler: ReduceLROnPlateau. 100 epoch, bez augmentací.



StarDist – inference a výsledky

- **Ensemble inference:** průměrování predikcí ze všech 5 modelů.
- Výsledky jednotlivých foldů (fixní práh 0.5): $\text{DetA} = 0.8129 \pm 0.0224$, nejlepší Fold 4: $\text{DetA} = 0.8286$.
- Ensemble threshold sweep: nejlepší $p = 0.6$, NMS = 0.35 → $\text{DetA} = 0.906$. (*Pozn.: hodnota nadhodnocená – každý val. snímek viděn 4/5 modely.*)



Porovnání detektorů

Detektor	Trénovací data	DetA
StarDist (120 val.)	120 (k-fold)	0.821 ± 0.019
StarDist (162 val.+annot.)	162 (k-fold)	0.813 ± 0.022
HRNet	3000 + 2000 (syntetická v2)	0.763
SAM3	0 (pretrained)	0.669
U-Net++	500 (syntetická)	0.620

- Méně kvalitních, reálných dat překonává více syntetických dat.
- Přidání 42 HITL anotací mírně zhoršilo výsledky – možný distribution shift.

Děkujeme za porornost!

Matyáš Veselý, Ruslan Guliev

FJFI ČVUT

veselm73@cvut.cz
gulierus@cvut.cz